



МАШИННО ОБУЧЕНИЕ • PYTHON

Сегментация на клиенти чрез RFM анализ и K-Means

Поведенческа сегментация на клиенти чрез Recency, Frequency, Monetary метрики и неконтролирано машинно обучение

Филип Пенчев

студент „Анализ на данни“ · ФМИ

Бизнес проблемът

Как да превърнем суровата транзакционна история в маркетингово действие?



ЦЕЛТА

Как онлайн търговец да идентифицира различните типове клиенти според поведението им на пазаруване вместо да третира всички еднакво?



ПРЕДИЗВИКАТЕЛСТВОТО

Суровите данни са само списък от транзакции. Трябва да ги превърнем в поведенчески показатели и да намерим скрити модели без предварително зададени етикети (unsupervised learning).



РЕШЕНИЕТО

Изчисляване на RFM показатели (Recency, Frequency, Monetary) за всеки клиент и групирането им чрез алгоритъма K-Means в ясни, приложими сегменти.

Данни и технологичен стек

Реални транзакционни данни и инструментариум за машинно обучение

DB

ДАННИТЕ

Online Retail Dataset (UCI Machine Learning Repository)

Реални транзакции на британски онлайн търговец за периода 2010–2011 г.

Ключови колони:

`CustomerID`, `InvoiceDate`, `Quantity`, `UnitPrice`

Заредено директно с `pd.read_excel(url)`, ~540 000 реда → 4 338 уникални клиенти след почистване.

Py

Python + pandas

Извличане, почистване и агрегация на транзакционните данни по клиент.

sk

scikit-learn

Алгоритъмът K-Means за неконтролирано клъстериране на клиентите.

viz


matplotlib & plotly

Визуализация на данните и интерактивно 3D моделиране на сегментите.

От данни към решение


Как изглеждат клъстерите и какво разказват за клиентите

К-Means клъстери в RFM пространството



3D пространство R-F-M Интерактивна визуализация (plotly), тук статичен изглед. K-Means разделя клиентите на видимо различни групи.

Бизнес профил на клъстерите (реални средни стойности)



Бизнес профил cluster_summary извежда средните R, F и M за клъстер - основата за бизнес интерпретацията им.

Логиката зад модела

От суровите транзакции до готовите клиентски сегменти

1

RFM показатели

groupby(CustomerID): Recency - дни от последна поръчка, Frequency - брой уникални фактури (nunique), Monetary - сума от TotalSum.



2

Log + стандартизация

np.log1p изглажда силно изкривените Frequency и Monetary, а StandardScaler ги привежда към еднакъв мащаб преди клъстериране.



3

KMeans(n_clusters=4)

Фиксирани 4 клъстера, random_state=42, n_init=10. fit_predict() връща етикет 0-3 за всеки клиент в новата колона Cluster.

Накрая cluster_summary осреднява R, F и M по клъстер - числата, които превръщат етикетите 0-3 в бизнес профили.

Резултатът и демонстрация

Четири разпознаваеми клиентски сегмента, готови за маркетингово действие

БИЗНЕС ИНТЕРПРЕТАЦИЯ НА КЛЪСТЕРИТЕ 0-3

● Клъстер 1 - VIP	$R\ 12.1 \cdot F\ 13.7 \cdot M\ £8074 \cdot n=716$
● Клъстер 2 - Лоялни	$R\ 71.1 \cdot F\ 4.1 \cdot M\ £1803 \cdot n=1173$
● Клъстер 0 - Нови	$R\ 18.1 \cdot F\ 2.1 \cdot M\ £552 \cdot n=837$
● Клъстер 3 - В риск	$R\ 182.5 \cdot F\ 1.3 \cdot M\ £344 \cdot n=1612$

Най-големият сегмент (1612 кл. от 4338, ~37%) е „в риск“ - приоритет за реактивиращи кампании, докато VIP (716 кл.) носят несравнимо най-висока стойност.



Тествай модела на живо

Пълният код, данните и 3D визуализациите в GitHub репозиторията на проекта.

github.com/philippenchev98/rfm-customer-segmentation

▶ [Open in Colab](#)



Сканирай за директен достъп до репозиторията